

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN • KHOA KHOA HỌC MÁY TÍNH

PHÁT HIỆN GIAN LẬN TÀI CHÍNH

Ứng dụng Machine Learning & Deep Learning trên Tập dữ liệu PaySim

Môn học: CS106 — Trí tuệ Nhân tạo | GVHD: PGS.TS. Nguyễn Đình Hiến

NHÓM
09

Trần Hoàng Hôn (26410046) • Đặng Chí Thanh (25730067) • Nguyễn Duy Khang (26410055)
Hoàng Cao Sơn (25730061) • Vũ Văn Duy (26410031) • Bùi Thị Mỹ Cẩm (25730013) • Phạm Thanh Trung (26410141)

TP. Hồ Chí Minh, Tháng 09/2026

NỘI DUNG BÁO CÁO & LỘ TRÌNH

01

Giới thiệu & Problem Formulation

Bối cảnh tài chính, bài toán Extreme Class Imbalance và phát biểu bài toán.

02

Exploratory Data Analysis & Feature Engineering

Khu biệt loại giao dịch, dấu vết rút cạn số dư và 14 engineered features.

03

Phương pháp Đề xuất & ML Pipeline

Resampling (SMOTE/ADASYN), Random Forest, XGBoost và Deep Autoencoder.

04

Kết quả Thực nghiệm & Đánh giá So sánh

Benchmark hiệu năng, Confusion Matrix, Feature Gain và phân tích sai số.

05

Hệ thống Thực thi & Hướng Phát triển

Dashboard Streamlit real-time, đóng góp cốt lõi, hạn chế và lộ trình GNN.

PHẦN 01

GIỚI THIỆU & PROBLEM FORMULATION

- Bối cảnh Công nghiệp & Sự bùng nổ Mobile Money
- Thách thức Extreme Class Imbalance ($\sim 0.13\%$) & Asymmetric Cost
- Phát biểu Bài toán Hình thức & Mục tiêu Nghiên cứu

Động lực Nghiên cứu & Thách thức Kỹ thuật

1. Bối cảnh Thực tiễn & Quy mô

- Giao dịch tiền di động (Mobile Money) tăng trưởng bùng nổ, kéo theo các thủ đoạn gian lận tinh vi.
- Hệ thống phòng thủ đòi hỏi độ trễ suy luận thời gian thực (Inference Latency < 100ms) trước khi dòng tiền bị rút khỏi hệ thống.

2. Extreme Class Imbalance (~0.13%)

- Giao dịch gian lận chỉ chiếm ~1 trên 800 giao dịch trong tập dữ liệu PaySim.
- Cost Asymmetry: Bỏ sót gian lận (False Negative) gây tổn thất vốn trực tiếp, trong khi Báo động nhầm (False Positive) gây phiền hà khách hàng.

3. Non-Stationary Fraud Patterns

- Kẻ gian lận tục biến đổi phương thức luân chuyển tiền để lẩn tránh các bộ lọc luật tĩnh (rule-based).

Class Target	$Y \in \{0, 1\}$	1 = Fraudulent (Gian lận), 0 = Legitimate
Imbalance Ratio	$IR = 0.13\%$	1,643 ca gian lận trên 1.3M giao dịch
Primary Metric	Max PR-AUC	Tối đa hóa Recall trên lớp gian lận hiếm
Cost Asymmetry	$C_{FN} \gg C_{FP}$	Trọng số phạt tổn thất bất đối xứng ($C_{FN} \gg C_{FP}$)

Mục tiêu Nghiên cứu

- Xây dựng end-to-end ML pipeline chuẩn, đảm bảo Leak-Free tuyệt đối.
- Thiết kế các phương trình domain feature bất trộn sai lệch sổ cái tài khoản.
- Benchmark mô hình Ensemble Trees với Deep Unsupervised Autoencoder.
- Triển khai interactive dashboard phục vụ ra quyết định thời gian thực.

Tập Dữ liệu PaySim: Thuộc tính Thống kê

6,362,620 -> 200,000

Dataset Scaling
Stratified downsampling bảo toàn 100% gian lận

8,213

Positive Instances (isFraud = 1)
Giao dịch gian lận nhãn ground-truth

11 -> 14 Features

Feature Space Mở rộng
Bổ sung các phương trình sai lệch số dư

Feature Name	Data Type	Domain Description & Ý nghĩa Nghiệp vụ
step	Integer	Time step theo giờ (1..744, tương ứng 30 ngày mô phỏng)
type	Categorical	Loại giao dịch: CASH_OUT, TRANSFER, PAYMENT, CASH_IN, DEBIT
amount	Continuous	Số tiền thực hiện giao dịch (đơn vị tiền tệ cục bộ)
oldbalanceOrg / newbalanceOrig	Continuous	Số dư trước và ngay sau giao dịch của tài khoản nguồn (sender)
oldbalanceDest / newbalanceDest	Continuous	Số dư trước và ngay sau giao dịch của tài khoản đích (recipient)

PHẦN 02

EXPLORATORY DATA ANALYSIS & FEATURE ENGINEERING

- Phân tích Dấu vết Hành vi Thực nghiệm (Behavioral Signatures)
- Công thức Toán học của 14 Engineered Domain Features
- Xử lý Mất cân bằng Lớp: SMOTE vs. ADASYN Formulation

Exploratory Data Analysis: Dấu vết Hành vi Cốt lõi

Finding 1: Category Confinement

100% FRAUD CONCENTRATION

- 100% giao dịch gian lận chỉ xuất hiện ở TRANSFER và CASH_OUT.
- Các loại PAYMENT, CASH_IN và DEBIT hoàn toàn không có gian lận (0%).
- Pipeline Action: Lọc dữ liệu chỉ giữ lại TRANSFER & CASH_OUT để triệt tiêu 70% nhiễu.

Finding 2: Total Account Drain

97.56% OF FRAUD CASES

- Ở 97.56% giao dịch gian lận, tài khoản nạn nhân bị rút cạn sạch (newbalanceOrig == 0).
- Kẻ gian tối đa hóa hiệu suất rút tiền trước khi bị hệ thống phát hiện định danh.
- Key Signal: Tỷ lệ rút cạn tài khoản đóng vai trò phân loại chính.

Finding 3: Destination Ledger Mismatch

ZERO DELTA ANOMALY

- Tỷ lệ lớn giao dịch gian lận không làm tăng số dư tài khoản đích.
- Phản ánh tài khoản rác (mule account) hoặc luân chuyển rửa tiền đa tầng tức thì.
- Key Signal: Destination discrepancy error vạch trần hành vi rút tiền bất hợp pháp.

Feature Engineering: 14 Synthesized Domain Predictors

1. Origin Balance Error (Delta Orig)

$$\Delta_{\text{orig}} = \text{oldbalanceOrg} - \text{amount} - \text{newbalanceOrig}$$

Đo lường sai lệch giữa số dư kỳ vọng và số dư thực tế của tài khoản nguồn sau giao dịch.

2. Destination Balance Error (Delta Dest)

$$\Delta_{\text{dest}} = \text{oldbalanceDest} + \text{amount} - \text{newbalanceDest}$$

Theo dõi các sai lệch luân chuyển tiền hoặc không ghi có tại tài khoản đích.

3. Full Account Drain Indicator Flag

$$I_{\text{drain}} = \mathbb{I}(\text{oldbalanceOrg} > 0 \wedge \text{newbalanceOrig} = 0)$$

Biến nhị phân bắt trọn hành vi vét sạch toàn bộ tài khoản trong 1 bước duy nhất.

Feature Space	$d = 14$	Không gian 14 đặc trưng số học sau Feature Engineering
Origin Error	<code>Err_orig</code>	Bắt trọn sai lệch số cái nguồn (49.9% gain)
Dest Error	<code>Err_dest</code>	Ghi nhận bất thường số dư tài khoản đích
Amount Ratio	<code>R_amt</code>	$\text{amount} / (\text{oldbalanceOrg} + 1)$
Hour of Day	<code>h in [0..23]</code>	step % 24 (chu kỳ thời gian trong ngày)
Overnight Flag	<code>I_night</code>	1 nếu hour in [0..5] (khung giờ đêm)

Feature Importance Insights

- Các biến ledger error đóng góp hơn 97% feature split gains của cây quyết định.
- Chu kỳ thời gian (hour) cô lập các cuộc tấn công theo kịch bản tự động vào ban đêm.
- Toàn bộ features được scale nghiêm ngặt CHỈ trên tập Train để chống Data Leakage.

Xử lý Mất cân bằng Lớp: SMOTE vs. ADASYN

Accuracy Paradox in Imbalanced Classification

- Một baseline ngây thơ dự đoán 100% "Hợp lệ" đạt Accuracy 99.87% nhưng bỏ sót 100% gian lận.
- Evaluation Mandate: Lựa chọn model phải được dẫn dắt tuyệt đối bởi Precision, Recall, F1-Score và PR-AUC.

SMOTE Interpolation Formulation

$$x_{\text{new}} = x_i + \lambda(x_{z_i} - x_i), \quad \lambda \sim U(0,1)$$

Nội suy mẫu nhân tạo thiếu số dọc theo đoạn thẳng nối các láng giềng k-NN trong latent feature space.

ADASYN Density-Weighted Resampling

$$r_i = \Delta_i/K, \quad \Gamma_i = r_i / \sum_{j=1}^m r_j$$

Sinh mẫu nhân tạo thiếu số theo phân phối trọng số mật độ (Γ_i) ở vùng decision boundary.

Đúc kết Thực nghiệm (Empirical Insights)

- SMOTE tạo decision boundary rõ nét hơn với tỷ lệ False Positive thấp hơn.
- ADASYN over-synthesize ở vùng chông lẩn nhiễu, làm giảm nhẹ chỉ số Precision.

PHẦN 03

PHƯƠNG PHÁP ĐỀ XUẤT & PIPELINE

- Kiến trúc Pipeline Toàn diện Chuẩn Leak-Free
- Supervised Learning: Random Forest (Bagging & MDI Importance)
- Gradient Boosting: XGBoost (Regularized GBDT & Taylor Expansion)
- Unsupervised Learning: Deep Autoencoder (Manifold Reconstruction)

End-to-End Leak-Free Machine Learning Pipeline

1

Filtering

Giữ lại TRANSFER &
CASH_OUT

2

Feature Eng.

Tính toán 14
mathematical
features

3

Stratified Split

Tách 80/20
Train/Test phân tầng

4

Resampling

SMOTE / ADASYN CHỈ
trên Train fold

5

Training

Fit RF, XGBoost &
Autoencoder

6

Evaluation

Inference trên tập
Test độc lập
(N=40,000)

Quy chuẩn Khắt khe Chống Data Leakage

- Resampling (SMOTE/ADASYN) tuyệt đối CHỈ thực hiện SAU KHI phân chia Train/Test trên tập Train.
- StandardScaler normalization chỉ fit trên tập Train và transform mù trên tập Test.
- Tuyệt đối không để rò rỉ thông tin tập Test vào feature representation hay hyperparameter tuning.

Supervised Architecture 1: Random Forest Ensemble

Ensemble Bagging Architecture:

- Xây dựng tập hợp B Decision Trees độc lập huấn luyện trên các bootstrap sub-samples.
- Lấy trung bình dự đoán giúp giảm mạnh variance mà không làm tăng bias, chống feature multicollinearity cực tốt.
- Cung cấp xếp hạng tầm quan trọng đặc trưng theo Mean Decrease in Impurity (Gini MDI).

Cấu hình Hyperparameter Tối ưu:

- n_estimators: 200 (SMOTE) / 500 (ADASYN)
- max_depth: 20 | min_samples_split: 2 | max_features: "sqrt" | class_weight: "balanced"

Gini Impurity & MDI Split Criterion

$$G(p) = 1 - \sum_{k=1}^c p_k^2, \quad \Delta G = G_{\text{parent}} - \sum_c \frac{N_c}{N} G_c$$

Mỗi phân nhánh tối ưu hóa mức giảm Gini Impurity trên các feature subspace được chọn ngẫu nhiên.

Ensemble Size	B = 200 / 500	Tổng số cây bagged trong rừng
Depth Limit	d_max = 20	Giới hạn độ sâu (chống Overfitting)
Split Metric	Gini Impurity	Tiêu chuẩn đo impurity thông tin
Feature Subset	m = sqrt(d) ~ 4	Kích thước feature subspace ngẫu nhiên

Thế mạnh Kiến trúc

- Peak Precision: Chỉ sinh duy nhất 1 False Positive trên 38,357 test samples.
- High Interpretability: Decision path minh bạch và feature importance rõ ràng.
- Hạn chế: Thời gian training tương đối lâu (~1187s).

Supervised Architecture 2: XGBoost Classifier

Gradient Boosted Decision Trees (GBDT):

- Tối thiểu hóa hàm mục tiêu có regularization bằng khai triển Taylor bậc 2.
- Tích hợp explicit L1/L2 regularization trên lá để kiểm soát độ phức tạp của cây.
- High Throughput: Training chỉ mất ~41.6s (nhanh hơn 28.5 lần so với Random Forest ~1187s).

Tuned Hyperparameter Setup:

- learning_rate (eta): 0.2 | n_estimators: 300 | max_depth: 8
- subsample: 0.85 | colsample_bytree: 1.0 | eval_metric: "logloss"

Regularized Objective Function (Taylor Bậc 2)

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

trong đó g_i và h_i là 1st và 2nd order gradients của loss function theo dự đoán trước.

Objective	Loss + Omega(f)	Hàm mục tiêu có regularization
Learning Rate	eta = 0.2	Hệ số co ngót bước học (eta = 0.2)
Max Depth	d = 8	Độ sâu cây tối đa mỗi boosting round
Subsample	rho = 0.85	Tỷ lệ lấy mẫu hàng ngẫu nhiên (rho = 0.85)

Ưu thế trong Môi trường Production

- F1-score đạt 99.63%, gần như tương đương tuyệt đối với Random Forest (99.73%).
- Single-sample inference latency cực thấp: < 0.5ms.
- Lý tưởng để triển khai kiểm duyệt giao dịch real-time tại payment gateway.

Unsupervised Architecture 3: Deep Autoencoder

One-Class Semi-Supervised Anomaly Detection:

- Mạng được huấn luyện HOÀN TOÀN trên legitimate transactions (N = 122,744 normal samples).
- Học low-dimensional manifold biểu diễn hành vi giao dịch bình thường.
- Anomaly Scoring: Giao dịch gian lận không thể tái tạo chuẩn -> Reconstruction Error (MSE) tăng vọt.

Cấu hình Kiến trúc Mạng:

- Symmetric Topology: 16 -> 8 -> 4 (Bottleneck) -> 8 -> 16
- Optimizer: Adam (lr=1e-3) | Loss: MSE | Threshold: tau = 0.045456 (95th percentile)

Reconstruction Loss & Decision Cutoff

$$\mathcal{L}_{\text{MSE}}(x, \hat{x}) = \frac{1}{d} \sum_{j=1}^d (x_j - \hat{x}_j)^2, \quad \hat{y} = \mathbb{I}(\mathcal{L}_{\text{MSE}} > \tau)$$

Các mẫu có MSE vượt quá ngưỡng validation 95th percentile (tau) được phân loại là Anomalous (Gian lận).

Bottleneck	$z \text{ in } \mathbb{R}^4$	Không gian biểu diễn ẩn nén ($z \text{ in } \mathbb{R}^4$)
Loss Function	$\text{MSE}(x, \hat{x}_{\text{hat}})$	Mean Squared Reconstruction Error (MSE)
Activation	ReLU / Linear	Non-linear hidden layer mappings (ReLU)
Decision Threshold	$\tau = 0.0455$	Ngưỡng quyết định 95th percentile ($\tau = 0.0455$)

Vai trò Phát hiện Tấn công Zero-Day

- Đạt 75.23% Recall dù hoàn toàn không quan sát fraud labels khi training.
- Đóng vai trò lớp phòng thủ bổ trợ đặc lực cho các attack signatures mới chưa từng xuất hiện.

PHẦN 04

KẾT QUẢ THỰC NGHIỆM & ĐÁNH GIÁ SO SÁNH

- Comprehensive Performance Benchmark (Precision, Recall, F1, ROC-AUC)
- Confusion Matrix & Đánh đổi False Alarm vs. Missed Fraud
- Feature Importance Attribution & Split Gain Contributions
- Autoencoder Anomaly Thresholding & Reconstruction Dynamics

Kết quả Thực nghiệm: So sánh Đối chuẩn (N = 40,000)

Model Architecture	Resampling	Precision	Recall	F1-Score	ROC-AUC	Train Time
Random Forest	SMOTE	0.9994	0.9951	0.9973 (Best)	0.9994	1187.7s
Random Forest	ADASYN	0.9982	0.9951	0.9966	0.9992	1167.5s
XGBoost	SMOTE	0.9976	0.9951	0.9963	0.9993	41.6s
XGBoost	ADASYN	0.9957	0.9951	0.9954	0.9994	41.5s
Autoencoder	None (One-Class)	0.3822	0.7523	0.5069	0.9318	215.3s

Đúc kết Thực nghiệm Cốt lõi

- RF + SMOTE đạt đỉnh F1-Score (99.73%) với chỉ duy nhất 1 False Positive trên 38,357 legitimate test samples.
- XGBoost đạt classification performance gần như tương đương (F1 99.63%) nhưng training time nhanh hơn 28.5 lần.
- Autoencoder phát hiện được 75.23% ca gian lận trong bối cảnh hoàn toàn unsupervised, không cần fraud labels.


Confusion Matrix & Phân tích Phân phối Sai số



Phân tích Đánh đổi giữa False Negative và False Positive

- Cả Random Forest và XGBoost chỉ bỏ sót 8 ca gian lận trên tổng số 1,643 true fraud cases (Recall = 99.51%).
- RF-SMOTE chỉ sinh đúng 1 False Alarm (FP=1), trong khi Autoencoder sinh 1,998 FP do đặc thù cắt ngưỡng 95% cutoff.

Feature Importance: XGBoost Decision Split Gains




Đúc kết Đặc trưng Quan trọng

- Top 2 features đóng góp > 97% vào tổng quyết định phân nhánh cây.
- Raw transaction amounts nếu không có sai số delta mang lại rất ít predictive power.

Insights từ XGBoost Feature Gain:

- **errorBalanceOrig** chiếm ~49.9% tổng trọng số phân nhánh của model.
- **newbalanceOrig** bổ sung thêm ~47.2% predictive power cho cây quyết định.
- **Tác động kết hợp:** Các engineered ledger discrepancies nắm giữ hơn 97% động lực phân loại gian lận, chứng minh tính hiệu quả vượt bậc của domain feature engineering.

Đánh giá So sánh: Precision, Recall & F1-Score




Tổng hợp Đối chuẩn

- SMOTE tạo decision boundary phân tách vượt trội hơn ADASYN.
- Supervised learning áp đảo hoàn toàn unsupervised reconstruction trên các dạng gian lận đã biết.

Phân tích Hiệu năng Resampling:

- SMOTE vượt trội hơn ADASYN một cách nhất quán trên mọi tree architectures.
- ADASYN sinh nhiều synthetic noise ở vùng boundary overlap, làm tăng nhẹ False Positives.
- Khuyến nghị: Triển khai XGBoost + SMOTE để tối ưu hóa inference throughput và fraud detection precision trong môi trường production.

Autoencoder Anomaly Thresholding & Decision Boundary



Threshold Calibration

- $\tau = 0.0455$ (95th percentile) tối ưu hóa trade-off curve của F1-Score.
- Unsupervised model gắn cờ thành công 1,236 sự kiện gian lận thực tế.

Động lực Quét Ngưỡng (Threshold Sweep):

- 95th Percentile ($\tau = 0.0455$):
Cân bằng giữa Recall (75.2%) và Precision (38.2%).
- 99.9th Percentile ($\tau = 0.7460$):
Precision tăng vọt lên 91.5% nhưng Recall giảm xuống 25.4%.
- Vai trò Vận hành: Đóng vai trò secondary zero-day defense layer đặc lực trước các hình thức gian lận mới chưa có label.

PHẦN 05

HỆ THỐNG THỰC THI & ĐỊNH HƯỚNG TƯƠNG LAI

- Streamlit Real-Time Inference Dashboard Architecture
- Tổng kết Đóng góp Học thuật & Kỹ thuật Cốt lõi
- Hạn chế Nghiên cứu & Graph Neural Network (GNN) Roadmap

Demo Trực quan: Dashboard Thời gian Thực trên Streamlit

Kiến trúc Real-Time Inference

- Giao diện Streamlit tinh gọn với dynamic risk probability gauges và visual status cards.
- Feature extraction engine tức thì chuyển đổi user input thành 14-dimension engineered vector.
- Pre-loaded serialized XGBoost và Random Forest pipelines qua Joblib.
- Single-transaction inference latency đạt mức sub-millisecond (< 1ms).

Các Kịch bản Mô phỏng Thực nghiệm

- Scenario 1 (Normal Transfer): Giao dịch tiêu chuẩn với biến động số dư hợp lệ -> Model Output: SAFE (Risk Probability < 0.1%).
- Scenario 2 (Account Drain): Chuyển tiền lớn khiến số dư nguồn về 0 -> Model Output: HIGH RISK FRAUD (Risk Probability > 99.8%).
- Batch CSV Scoring: Cho phép chấm điểm hàng loạt và xuất compliance audit report.

Tổng kết Đóng góp & Định hướng Nghiên cứu

Đóng góp Cốt lõi của Dự án

- Leak-Free Protocol: Stratified 80/20 split ngăn chặn hoàn toàn data contamination.
- Domain Feature Engineering: 14 synthesized features chiếm > 97% tree split gains.
- Superior Benchmark: F1-Score = 99.73% và Recall = 99.51% (chỉ bỏ sót 8 trên 1,643 frauds).
- Production Deployment: Dashboard Streamlit hoàn chỉnh phục vụ real-time risk screening.

Lộ trình Nghiên cứu Tương lai

- Graph Neural Networks (GNN): Ứng dụng GCN / GraphSAGE phát hiện structured money-laundering subgraphs.
- Streaming Ingestion: Tích hợp Apache Kafka / Flink phục vụ distributed sub-second streaming transactions.
- Explainable AI (XAI): Tích hợp SHAP / TreeExplainer phục vụ regulatory compliant transaction audit logs.

CHÂN THÀNH CẢM ƠN THẦY VÀ CÁC BẠN ĐÃ LẮNG NGHE!

CS106: TRÍ TUỆ NHÂN TẠO • BÁO CÁO BẢO VỆ ĐỒ ÁN • NHÓM 09

TÀI LIỆU THAM KHẢO HỌC THUẬT & REPOSITORY DỰ ÁN

- [1] E. A. Lopez-Rojas, A. Elmir, S. Axelsson. "PaySim: A Financial Mobile Money Simulator for Fraud Detection", 28th EMSS, 2016.
- [2] T. Chen, C. Guestrin. "XGBoost: A Scalable Tree Boosting System", Proc. 22nd ACM SIGKDD, 2016.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, W. P. Kegelmeyer. "SMOTE: Synthetic Minority Over-sampling Technique", JAIR, 2002.
- [4] L. Breiman. "Random Forests", Machine Learning, 45(1), pp. 5-32, 2001.
- [5] Mã nguồn Dự án: <https://github.com/uit-25730067-chithanh/CS106-Team09-Fraud-Detection>

Nhóm 09 rất mong nhận được những câu hỏi và góp ý quý báu từ Hội đồng!